

Tópicos avanzados de Algoritmos bioinspirados.

Dra. Miriam Pescador Rojas

Práctica 3. Algoritmo genético basado en descomposición para la búsqueda de reglas de asociación

Algoritmo evolutivo multiobjetivo basado en descomposición.

El algoritmo evolutivo multiobjetivo basado en descomposición (MOEA/D, por sus siglas en inglés, *Multi-Objective Evolutionary Algorithm based on Decomposition*) descompone un problema multiobjetivo en un conjunto de múltiples subproblemas mono-objetivo.

Elementos de MOEA/D.

1. **Descomposición:** MOEA/D define un conjunto de **vectores de peso (o dirección)** uniformemente distribuidos. Cada vector de peso está asociado a un subproblema (así como a un individuo de la población).
2. **Función escalar o agregativa:** Cada subproblema se formula utilizando una **función de agregación** que combina los múltiples objetivos del problema original en un único objetivo escalado, guiado por el vector de peso asignado (λ). Las funciones de agregación más comunes son:

- **Método de Tchebycheff (T-chebycheff):** Es el más popular y se enfoca en minimizar la máxima desviación ponderada desde el punto ideal (z).

$$\min g^{tch}(f(x)|\lambda) = \max_{1 \leq j \leq m} \{\lambda_j \cdot |f_j(x) - z_j|\}$$

- **Método Ponderado (Weighted Sum):** Combina los objetivos linealmente.

$$\min g^{ws}(f(x)|\lambda) = \sum_{i=1}^m \lambda_i \cdot (f_i(x) - z_i)$$

- **Método PBI (Penalty-Based Boundary Intersection):** Combina la distancia al vector de peso con una penalización por desviación.

$$\min g(x|\lambda^j) = d_1 + \theta d_2$$

Donde:

$$d_1 = \frac{\|((f(x) - z)T\lambda^j)\|}{\|\lambda^j\|},$$

$$d_2 = \|f(x) - (z - d_1\lambda^j)\|, (j = 1, 2, \dots, N)$$

3. **Búsqueda Basada en Vecindad:** La evolución de cada subproblema se realiza principalmente utilizando información de sus subproblemas **vecinos**. Dos subproblemas son vecinos si sus vectores de peso correspondientes están cerca en el espacio de objetivos. Esto asegura que la diversidad se mantenga localmente, ya que cada subproblema se enfoca en una parte específica del frente de Pareto (PF)

El pseudocódigo de **MOEA/D** es el siguiente:

```

Input: the number of objectives  $m$ ,
         the decomposition parameter  $H$ ,
         the number of weight vectors and solutions  $N$ ,
         the neighborhood size  $T$ 
Output: the non-dominated set of solutions
-----
 $L = \{\lambda^1, \lambda^2, \dots, \lambda^N\} \leftarrow$  Generate weight vectors ( $H, m$ )
for each  $\lambda^i \in L$  do
     $B_i = \{i_1, i_2, \dots, i_T\} \leftarrow$  Find nearest neighbor weight indices
end for
 $P = \{x^1, x^2, \dots, x^N\} \leftarrow$  Randomly generate the population
 $z \leftarrow$  Update Ideal point ( $P$ )
repeat
    for each  $i \in \{1, 2, \dots, N\}$  do
         $x^p, x^q \leftarrow$  Randomly select parents ( $B_i$ )
         $y \leftarrow$  Generate offspring ( $x^p, x^q$ )
         $z \leftarrow$  Update Ideal point ( $y$ )
        for each  $j \in B_i$  do
            if  $g(y | \lambda^j) < g(x^j | \lambda^j)$  then
                 $x^j \leftarrow y$ 
            end if
        end for
    end for
until The termination criterion is satisfied
return The non-dominated solutions picked from  $P$ 

```


Initialization

Search

Para la inicialización de los vectores de peso (dirección) usamos el método de Das and Dennis, como sigue:


- ▶ Se utiliza un parámetro H y el número de objetivos m .
- ▶ Cada elemento de $\lambda^i = (\lambda_1^i, \lambda_2^i, \dots, \lambda_m^i)$ incluye alguno de los elementos $\left\{\frac{0}{H}, \frac{1}{H}, \frac{2}{H}, \dots, \frac{H}{H}\right\}$.
- ▶ Los vectores generados son $N = C_{H+m-1}^{m-1}$ pesos que satisfacen $\sum_{j=1}^m \lambda_j^i = 1.0$.

Gráficamente:




Determinación de los k vecinos de cada vector



Example : Neighbor size $T=3$



Example : Neighbor size $T=3$



El proceso de cruce se realiza con los individuos del mismo vecindario, se actualiza el vector ideal si este mejora y se verifica si el nuevo individuo reemplaza a uno o varios de los individuos del vecindario.



Minería de reglas de asociación

La minería de datos es un campo de las ciencias computacionales que aplica técnicas de análisis a grandes cantidades de información para extraer conocimiento a través de modelos de clasificación, regresión o asociación que tienen como objetivos describir tendencias, extraer patrones y predecir comportamientos.

La minería de reglas de asociación es una técnica de análisis de datos que utiliza **expresiones lógicas** para descubrir **relaciones de interés** entre las variables a estudiar. Para evaluar el grado de interés de una regla de asociación se utilizan medidas estadísticas, tales como: soporte, confianza y ascenso. Para realizar una minería más efectiva mediante reglas de asociación es necesario integrar **conocimiento del dominio del problema**.

Ejemplo de regla lógica a partir de un análisis de los datos de un caso.

En una tienda departamental, si sus clientes tiene **edades entre 20 y 30 años**, **trabajan** y son **solteros** tienden a **comprar videojuegos**.

$$[Edad=[20-30]] \wedge [Trabajan=Si] \wedge [Estado\ civil=soltero] \rightarrow [Articulos=videojuegos]$$

Es importante entender que esta regla lógica ocurre con una cierta probabilidad (p. ej. 0.85). Esto se cumple, específicamente para esa tienda y con el análisis de registro de clientes de un determinado tiempo. Este hallazgo o patrón puede cambiar dependiendo de la época del año, el registro de otra tienda y otras variables externas.

La minería de reglas de asociación fue propuesta en 1994, por Agrawal et al., usando el algoritmo conocido como **A priori**.

La minería de reglas de asociación ha tenido un gran interés en la comunidad de IA para el aprendizaje máquina, sus aplicaciones han sido diversas, por ejemplo:

- Análisis de mercados (Nisbet et al., 2018),
- Diagnóstico médico (Xu et al., 2022),

- Análisis de secuencias de proteínas (Gupta et al., 2006)

Aplicar mecanismos de minería de datos, genera típicamente una **gran cantidad de reglas de asociación** que a su vez deben analizarse para ser interpretadas.




Figure 1: The basic ARM pipeline.

Medidas de calidad para las reglas de asociación

$$supp(X \Rightarrow Y) = \frac{n(X \cap Y)}{N},$$

El soporte mide la proporción que contiene el patrón $X \rightarrow Y$, en el conjunto de datos.

$$conf(X \Rightarrow Y) = \frac{n(X \cap Y)}{n(X)},$$

La confianza estima la probabilidad condicional $P(Y|X)$, es decir encontrar Y bajo la condición de que X existe.

$$lift(X \Rightarrow Y) = \frac{supp(X \cap Y)}{supp(X) \times supp(Y)},$$

El ascenso es la relación del soporte observado de que X y Y surgen juntos en la regla, es decir si ambos conjuntos de elementos son independientes.

$$conv(X \Rightarrow Y) = \frac{1 - supp(Y)}{1 - conf(X \Rightarrow Y)},$$

La convicción evalúa la frecuencia con la que la regla hace una predicción incorrecta.

Medidas de interés de acuerdo con la tabla de confusión

Contingency Table

A 2×2 contingency table with counts for rule $X \Rightarrow Y$ in the transaction dataset. The counts are:

	Y	$\bar{Y}$
X	n_{XY}	$n_{X\bar{Y}}$
$\bar{X}$	$n_{\bar{X}Y}$	$n_{\bar{X}\bar{Y}}$

, requiere conocer la duración estimada de las tareas.

Consignas.

1. Implementar el **algoritmo** MOEA/D para buscar reglas de asociación que optimicen simultáneamente medidas de interés como proceso de minería de datos. Deberá probar la función de escalarización PBI (con $\theta=5.0$).
2. Base de datos. La base de datos a emplear tiene que ver con información de pacientes con diabetes para más detalles sobre la decodificación revise el siguiente enlace <https://www.kaggle.com/datasets/priyamchoksi/100000-diabetes-clinical-dataset/data>.
3. La **codificación** del individuo se definirá como un diploide con representación entera. El primer cromosoma (color azul) indica si la variable no aparece en la regla con el valor 0, o si toma alguna posición en la regla lógica, el valor de 1 si se ubica en el antecedente (X) o el valor 2 si esta variable se ubica en el consecuente (Y). Mientras que el cromosoma en color verde indica el valor que tiene la variable discretizada. Por ejemplo, Sexo = 1 significa que la persona es hombre.

Codificación.

Sexo	edad	IMC	Colesterol	triglicéridos	Glucosa	hipertensión	Tipo diab
1	1	0	0	2	2	1	0
1	3	0	0	1	2	1	0

Decodificación.

$\text{sexo} = \text{hombre} \wedge \text{edad} = [40,45] \wedge \text{hipertensión} = \text{SI} \Rightarrow \text{trigliceridos} = [1.1, 2.0] \wedge \text{glucosa} = \text{limite}$

Nota. Si un alelo del primer cromosoma tiene el valor cero, el alelo correspondiente en el segundo cromosoma también es 0, de lo contrario no tiene sentido.

4. Funciones objetivo.

Las funciones objetivo del problema se relacionan con las medidas de calidad de la regla lógica estas pueden ser clásicas tales como soporte, confianza o ascenso o pueden buscar medidas de interés o correlación entre conjuntos de atributos y valores. Para esta práctica exploraremos 2 casos de problemas multiobjetivo.

Problema de optimización 1. Considera optimizar las medidas casual-support, casual-support, Cross-Support Ratio.

Maximizar las ecuaciones

$$\text{casual-supp} = \text{supp}(X \cup Y) + \text{supp}(\bar{X} \cup \bar{Y}) = P(X \cap Y) + P(\bar{X} \cap \bar{Y})$$

$$\text{casual-conf} = \frac{1}{2}[\text{conf}(X \Rightarrow Y) + \text{conf}(\bar{X} \Rightarrow \bar{Y})] = \frac{1}{2}[P(Y|X) + P(\bar{Y}|\bar{X})]$$

$$\text{maxConf}(X \Rightarrow Y) = \max\{\text{conf}(X \Rightarrow Y), \text{conf}(Y \Rightarrow X)\} = \max\{P(Y|X), P(X|Y)\}$$

Problema de optimización 2. En este consideramos las medidas de Jaccard, Coseno y coeficiente de correlación phi y kappa.

Maximizar las medidas.

$$\text{jaccard}(X \Rightarrow Y) = \frac{\text{supp}(X \cup Y)}{\text{supp}(X) + \text{supp}(Y) - \text{supp}(X \cap Y)} = \frac{P(X \cap Y)}{P(X) + P(Y) - P(X \cap Y)}$$

$$\text{cosine}(X \Rightarrow Y) = \frac{\text{supp}(X \cap Y)}{\sqrt{(\text{supp}(X)\text{supp}(Y))}} = \frac{P(X \cap Y)}{\sqrt{P(X)P(Y)}} = \sqrt{P(X|Y)P(Y|X)}$$

$$\phi(X \Rightarrow Y) = \frac{nn_{XY} - n_X n_Y}{\sqrt{n_X n_Y n_{\bar{X}} n_{\bar{Y}}}} = \frac{P(X \cap Y) - P(X)P(Y)}{\sqrt{P(X)(1 - P(X))P(Y)(1 - P(Y))}}$$

$$\kappa(X \Rightarrow Y) = \frac{P(X \cap Y) + P(\bar{X} \cap \bar{Y}) - P(X)P(Y) - P(\bar{X})P(\bar{Y})}{1 - P(X)P(Y) - P(\bar{X})P(\bar{Y})}$$

NOTA. Si alguna de las medidas de

asociación se indetermina o genera un valor infinito, la regla de asociación deberá descartarse de la población, pero se almacenará en un archivo externo.

5. Operadores de variación.

4.1 Implemente un operador de recombinación “**cruza de n puntos**”. Ejemplo

Padre 1

Sexo	edad	IMC	Colesterol	triglicéridos	Glucosa	hipertensión	Tipo diab
1	1	0	0	2	2	1	0
1	3	0	0	1	2	1	0

Padre 2

Sexo	edad	IMC	Colesterol	triglicéridos	Glucosa	hipertensión	Tipo diab
0	1	2	1	0	1	0	2
0	2	1	2	0	1	0	3

Hijo 1

Sexo	edad	IMC	Colesterol	triglicéridos	Glucosa	hipertensión	Tipo diab
1	1	2	1	0	2	1	2
1	3	1	2	0	2	1	3

Hijo 2

Sexo	edad	IMC	Colesterol	triglicéridos	Glucosa	hipertensión	Tipo diab
0	1	0	0	2	1	0	0

0	2	0	0	1	1	0	0
---	---	---	---	---	---	---	---

Nota. Es importante que después de aplicar el operador de cruce se tenga al menos un atributo en el antecedente y al menos 1 atributo en el consecuente. De lo contrario aplicar una mutación para reparar.

4.2 Operadores de mutación. Implemente las siguientes mutaciones:

- Mutación por extensión. Modificar (o activar) un atributo-valor aleatoriamente en alguna posición del cromosoma.

Sexo	edad	IMC	Colesterol	triglicéridos	Glucosa	hipertensión	Tipo diab
1	1	0	0	2	2	1	0
1	3	0	0	1	2	1	0

Sexo	edad	IMC	Colesterol	triglicéridos	Glucosa	hipertensión	Tipo diab
1	1	0	1	2	2	1	0
1	3	0	2	1	2	1	0

- Mutación por contracción. Modificar un atributo-valor **activo** en el cromosoma colocando en cero sus valores.

Sexo	edad	IMC	Colesterol	triglicéridos	Glucosa	hipertensión	Tipo diab
1	1	0	0	2	2	1	0
1	3	0	0	1	2	1	0

Sexo	edad	IMC	Colesterol	triglicéridos	Glucosa	hipertensión	Tipo diab
1	0	0	0	2	2	1	0
1	0	0	0	1	2	1	0

- Mutación de reemplazo. Modificar el valor de un atributo activo en el cromosoma.

Sexo	edad	IMC	Colesterol	triglicéridos	Glucosa	hipertensión	Tipo diab
1	1	0	0	2	2	1	0
1	3	0	0	1	2	1	0

Sexo	edad	IMC	Colesterol	triglicéridos	Glucosa	hipertensión	Tipo diab
1	1	0	0	2	2	1	0
1	2	0	0	1	2	1	0

6. Sugerencia de valores para los **hiper-parámetros** del algoritmo.

Tamaño de población 100 individuos.

Número de generaciones 300

Varie el porcentaje de cruce y mutación según los éxitos obtenidos en el intervalo [0.3-0.8]

7. **Metodología experimental**, ejecute 10 veces el algoritmo con diferente semilla para generación de números aleatorios. Y reporte el valor de las medidas de interés y el indicador de hipervolumen como en la práctica anterior (recuerde que puede usar algún framework).

8. Resultados

Cree 2 tablas por escenario de prueba donde se muestren las siguientes estadísticas de hipervolumen.

Escenario de Prueba 1.

Medida	Cassual-supp			Cassual-conf			Max-conf			Hipervolumen		
Generación	min	max	Prom (desv)	min	max	Prom (desv)	min	max	Prom (desv)	min	max	Prom(desv)
50												
100												
150												
200												
300												

Escenario de Prueba 2.

Med	Jaccard			Coseno			Phi			Kappa			Hipervolumen		
Gen	min	max	Prom (dv)	min	max	Prom (desv)	min	max	Prom (desv)	min	max	Prom (desv)	min	max	Prom (desv)
50															
100															
150															
200															
300															

Muestre las 3 reglas que obtuvieron los mejores resultados por medida y muestre la regla que se encuentra cerca de la rodilla del frente de Pareto.

Archivos con reglas de asociación.

- 7.1 Archivo csv con las 100 reglas de asociación donde se muestre el conjunto de atributos **decodificados** que definen el antecedente los que definen el consecuente y el valor de las medidas. Ejemplo

Antecedente	Consecuente	Cassual-supp	Cassual-conf	Max-conf
$sexo = hombre \wedge edad = [40,45] \wedge hipertensión = SI$	$trigliceridos = [1.1, 2.0] \bigwedge glucosa = limite$	0.7	0.5	0.4

- 7.2 Archivo con las reglas que se indeterminaron y mostrar en qué medida ocurrió la indeterminación (infinito).

Revise el artículo <https://www.sciencedirect.com/science/article/pii/S0957417423014033> y elija una gráfica que muestre el top 10 de los resultados en la ejecución media. Sugerencia: Graph plot powered by arulesViz.

9. Análisis de resultados.

Responda las siguientes preguntas.

- ¿Cuál es la medida que obtuvo los mejores valores por escenario?
- ¿Cuál es la relación entre la longitud de la regla (número de atributos y valores) y los mejores valores que se obtuvieron por medida de asociación?
- ¿Considera que hay hallazgos importantes en las reglas, cuáles?
- Explique que valores de hiper-parametros fueron los más exitosos.
- Indique que casos de medidas fueron los que se indeterminaron, por qué cree que ocurre esto y cómo se puede evitar.

10. Realice un **reporte** que incluya la siguiente estructura:

- Portada con los nombres de los integrantes comenzando por apellidos y en orden alfabético

Marco teórico, en máximo una hoja. Agregue la descripción de cada medida de asociación usando el enlace (<https://mhahsler.github.io/arules/docs/measures>) y un resumen de los gráficos para visualizar las reglas de asociación como se describe en <https://www.sciencedirect.com/science/article/pii/S0957417423014033>.

- Diseño del algoritmo con ejemplos de prueba y explicación del código asociado para cada caso.
- Pruebas de los 2 escenarios proporcionados, mostrando tabla de resultados y gráficas solicitadas.
- Respuestas a las preguntas solicitadas.
- Conclusiones individuales.

La fecha de entrega es el lunes 1 de diciembre a las 23:00 hrs, deberá tener revisiones previas en laboratorio o salón de clases. Por cada día de atraso se penalizará con el 10% de la calificación obtenida, el fin de semana cuenta como 1 solo día.

Referencias de interés.

https://michael.hahsler.net/research/association_rules/

<https://github.com/mhahsler/arulesViz>

<https://mhahsler.github.io/arules/docs/measures>

<https://www.mdpi.com/2297-8747/28/1/12>

<https://www.sciencedirect.com/science/article/pii/S0957417423014033>

<https://www.kaggle.com/datasets/priyamchoksi/100000-diabetes-clinical-dataset/data>